資料探勘 Mid-term --2

tags: 資料探勘

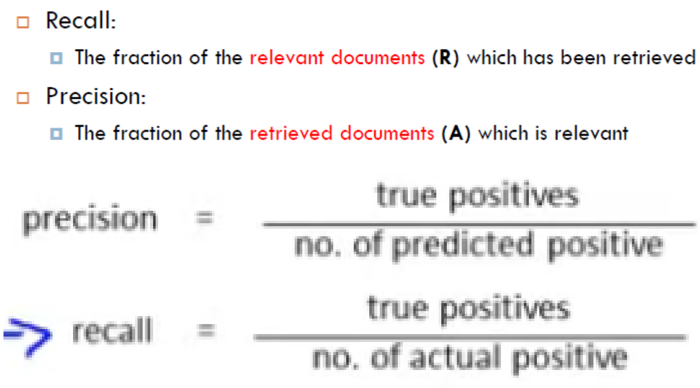

Precision - recall trade-off plot

> precision & recall 會因為不同情況對threshold設定大小的關係有不同的變動，例如僅有在非常高機率的預測下才會predict 1，則precision 會很高，但是recall 反而會下降(因為很多真實為1的都沒有predict為1，門檻太高。)

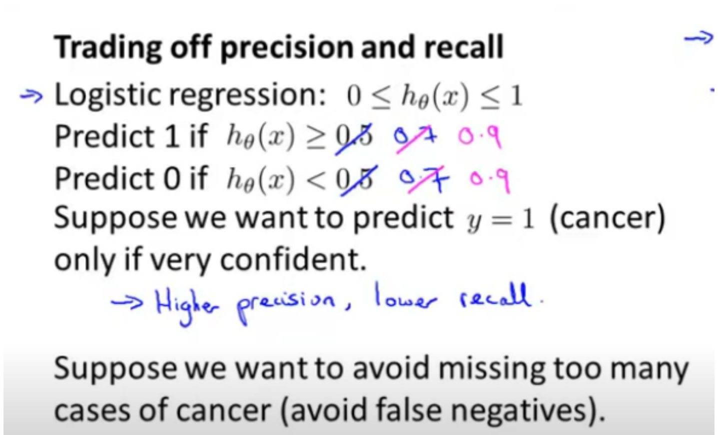

[precision & recall curve 資訊檢索 (https://ithelp.ithome.com.tw/articles/10192869)](https://ithelp.ithome.com.tw/articles/10192869)

Average Precision

在取出relevant的情況下，平均的precision。(每次的檢索結果會依照各個docu累進計算當下的precion & recall)

MAP

不同QUERY下，AP的平均 -> 考量每一個狀況的全盤指標

```
Average Precion 問題
1. 不能偵測單一不正常分類的部分
2. 預知道特定query的表現
```

Precision at k
針對搜尋引擎的問題，更在乎在總檢所文章總數為k時，precision為多少。
(特定的前幾筆文章，用precision at k衡量較能符合使用者感受)

但是一旦relevant文章總數高，自然precision at k也會高。

R-Precision

the precision at the R-th position in the ranking
將K設為relevant文章總數，則precision = recall(break even pnt)

marcoaveraging: 重視種類
所有類別的每一個統計指標值的算數平均值

microaveraging: 重視量
針對data所有instance不分類別得做confusion matrix

sensitivity : 所有ground truth為Positive的data中，總共有多少比例被正確分類為positive。

Specificity : 所有ground truth為negative總共正確抓出多少比例的true negative。

smaple class不balance時用accu不能完整表達模型的預測能力

ROC curve

一個sensitivity vs (1-specificity) 曲線，曲線變動來自於對於分類threshold的設定大小變動。

(true positive vs false positive rate)

y軸為答案是1，也正確猜1的比例，x是答案是0，但錯誤地猜成1的比例。

如果threshold設很低(很容易就猜1)，則sensitivity很高，但(1-specifitivity)也很高。

把threshold設更高，兩者可能皆會降低，要找一個threshold，使地有最大true posi/false posi比例。

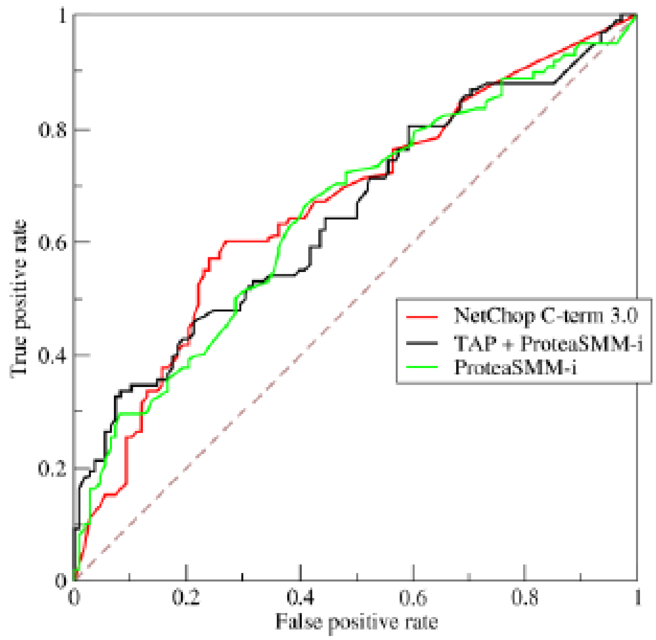

`對於imbalanced data，利用Precision or recall有更好地解釋能力。`

`auc 幫助判斷哪個分類器表現更好。(與閥值設定無關)`

在非常不balanced的data用roc做比較都有較stable的解釋力

Q1 : f1 score 和 break even pnt關係？

break even point -> precision = recall = f1 score

$$F1 = \frac{2 * precision * recall}{precision + recall}$$

- Q: Prove that the F1 is equal to the Dice coefficient of the retrieved and relevant document sets.
  - Dice(X, Y)=2|X∩Y|/|X|+|Y|
- A:
  - F1=2PR/(P+R), P=tp/(tp+fp), R=tp/(tp+fn)➔F1=2tp/(2tp+fp+fn)
  - |x|=**tp**+fp, |y|=**tp**+fn➔Dice(x, y)=tp/(2tp+fp+fn)

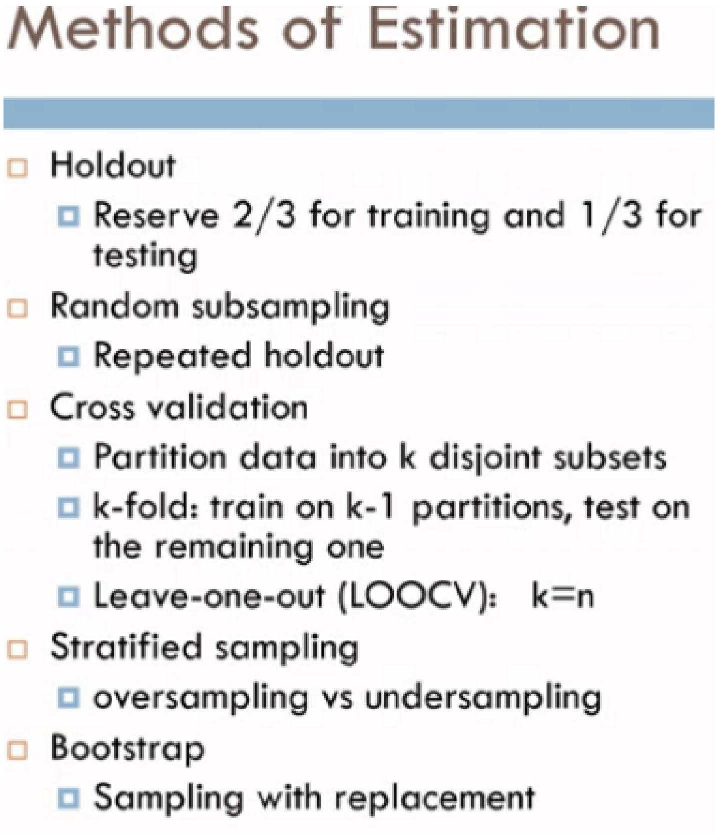

Ranked list

1. NDCG

度量一個query中各個docu的gain，根據docu在預測中排序的位置

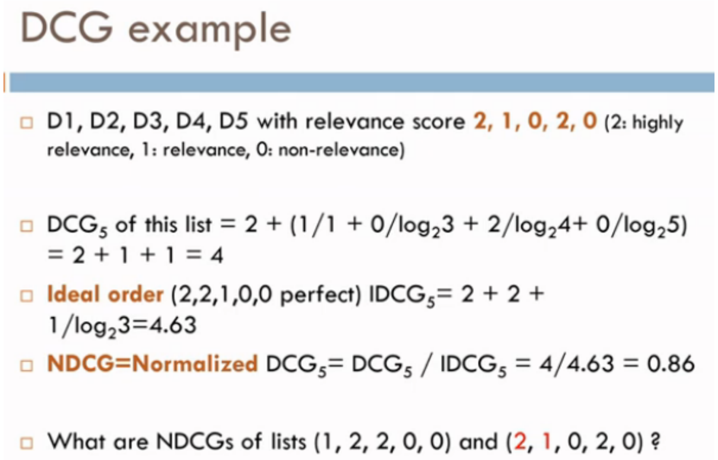

2. Kendall-tau

度量兩組具順序的list之間的關聯性。

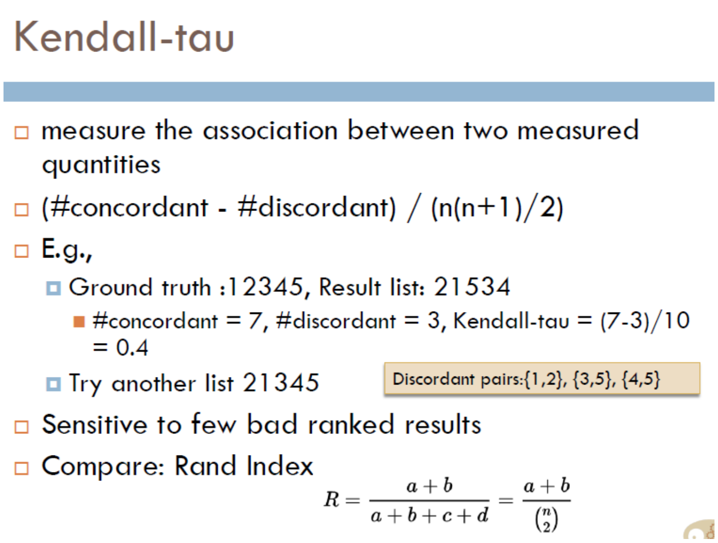

共有C n取2種組合。(兩組中一致的組合順序相同，視為一組concordant)

```
問題: 如果有一些bad ranked data，則kendall數值下降很快。
(sensitive)
```

Cohen’s Kappa

== 度量兩個raters之間的同意一致性。其中一個rater為分類器，另一個為ground truth。

```
假設兩個raters的決定互相獨立，可以算期望的agreement。
```

- Agreement Pr(a) = (10+15)/30=0.83
- Pr(e)
  - P(A=Y)=10/30=0.33
  - P(B=Y)=15/30=0.5
  - P(A=Y, B=Y) = 0.33*0.5 = 0.17
  - P(A=N,B=N) = 0.66*0.5 = 0.33
  - → Pr(e) = 0.17 + 0.33 = 0.5
- K = (0.83–0.5) / (1-0.5) = 0.66

		B	
		Y	N
A	Y	10	0
	N	5	15

Poor agreement = Less than 0.20
Fair agreement = 0.20 to 0.40
Moderate agreement = 0.40 to 0.60
Good agreement = 0.60 to 0.80
Very good agreement = 0.80 to 1.00

關聯法則

定義

support : fraction of transactions that contain an itemset

Mining Association Rules

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Example of Rules:

{Milk,Diaper} → {Beer} (s=0.4, c=0.67)
{Milk,Beer} → {Diaper} (s=0.4, c=1.0)
{Diaper,Beer} → {Milk} (s=0.4, c=0.67)
{Beer} → {Milk,Diaper} (s=0.4, c=0.67)
{Diaper} → {Milk,Beer} (s=0.4, c=0.5)
{Milk} → {Diaper,Beer} (s=0.4, c=0.5)

Observations:

- All the above rules are binary partitions of the same itemset: {Milk, Diaper, Beer}
- Rules originating from the same itemset have identical support but *can have different confidence*

Appriori algo

appriori property(anti monotone)

核心概念: 一個frequent itemset的所有subset必定也是freq
一組itemset的support不會大於其任一subset的support

```
若subset非freq，則其superset必定也非freq。
```

steps

1. 找出freq one itemset
2. 有交集用聯集產生candidate itemset (Lk self join)
3. subset check，如果subset非freq，則prun candidate itemset

如何加速計算candidates support的方法？

1. Hash Tree
2. FP growth

Rules Generation

對於一個freq itemset m，找出其subset p，做出inference p->(m-p)

reduction on database size

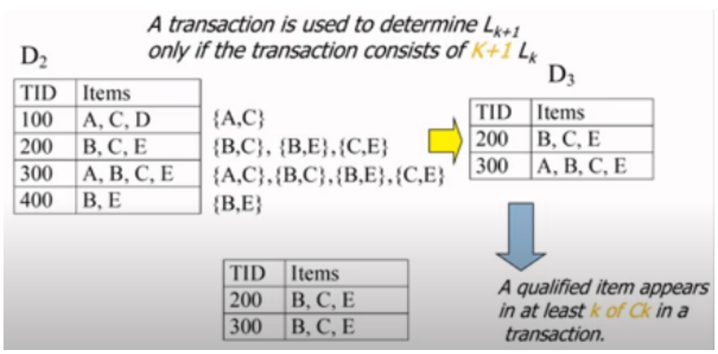

frequent pattern mining bottleneck

1. 多次掃描資料庫 costly
2. 產生太多的candidates list

FP-Growth

1. mining in main memery
2. 不做candidate generation

3. 頻率較多的items有更大的機率share item

> steps
> 1. 建立fp tree(header also)
>   - 掃描第一次db，建立freq one itemset
>   - 依照support大小排序，transactions扣除非freq後也照support排序
>   - 依序依照transaction插入tree建立fp tree
> 2. frequent pattern growth
>   - divide into 條件fp tree，跟一個header指向之freq item相連

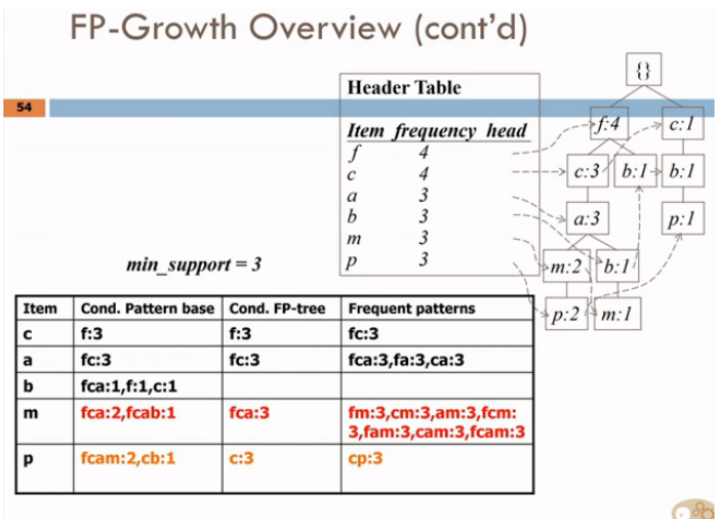

For each following evaluation criteria, please briefly describe ONE prediction system in which the criterion is important.

1. NDCG

   可應用於文章推薦或搜尋引擎系統，計算其檢索的相關性和排序後，衡量推薦結果的好壞，及推薦系統的預測能力。

2. Recall

   對於預測罕見癌症疾病模型，若沒有將真正為癌症的病人檢驗出來會造成嚴重後果，此時recall將會是此系統判斷好壞的評估標準。

   you should use recall when looking to predict wether a credit card charge is fraudulent or not. If you have a lot of false negatives, then you have a lot of fraudulent charges that are being labeled as not fraudulent and customers will have money stolen from them.

3. Top-1 precision

   依照預測結果機率最大的是正確答案(positive)，precision才會是1，所以模型若要從一個query中找出最佳預測結果，注重第一名的表現，就會用top-1 precision衡量。
   可以應用在圖像分類，因為最在乎一張圖片是否能成功預估某一類別(預測最高機率的類別要是ground truth)。

4. F1

   f1 score對於非常imbalanced的data有較好的分辨能力，比如要分辨...的分類能力。

5. Novelty

   可應用於文章推薦系統，且文章內容除了強調正確性以外，也強調每一篇文章的多樣性，要讓使用者感覺每篇文章都不同時，利用novelty可以反應該任務表現。

6. Precision

   Precision is a good evaluation metric to use when the cost of a false positive is very high and the cost of a false negative is low. For example, precision is good to use if you are a restaurant owner looking to buy wine for your restaurant only if it is predicted to be good by a classifier algorithm.

總結 (https://blog.csdn.net/shanshangyouzhiyangM/article/details/84943011)